



Projet Final

Analyse De Données E-Commerce : Évaluation De La Performance et des
tendances e-commerce Sephora

DIANA BENITEZ

Table des matières

1. Introduction	2
2. Glossaire.....	2
3. Données et préparation	3
3.1 Structure initiale des données	3
3.2 Choix de l'échantillon.....	3
3.3 Fusion des données	3
3.4 Transformation des données	4
3.5 Agrégation.....	5
4. Méthodologie	5
5. Résultats.....	6
5.1 Impact du prix	6
5.2 Exclusivité vs engagement	6
5.3 Type de produit	6
5.4 Produits les plus performants	7
5.5 Analyse temporelle de l'engagement (2008–2023)	7
5.6 Évolution de la satisfaction client.....	8
5.7 Insight clé	8
6. Recommandations business.....	8
7. Limites	9
8. Conclusion.....	9

1. Introduction

Dans un contexte de digitalisation du secteur de la beauté, les plateformes e-commerce jouent un rôle central dans la découverte, l'évaluation et la comparaison des produits. Les utilisateurs interagissent activement à travers les avis, les notes et les réactions, influençant ainsi la perception des produits.

Sephora, acteur majeur du marché de la beauté, propose une large gamme de produits et constitue un environnement pertinent pour analyser les comportements clients et les facteurs de performance des produits en ligne.

Cette étude analyse la performance des produits de beauté à partir de données issues de la plateforme Sephora, en s'appuyant sur des indicateurs comportementaux.

L'analyse porte sur la période 2008 à 2023, permettant d'observer l'évolution des comportements utilisateurs sur le long terme.

Dans ce contexte, il devient essentiel de comprendre les leviers de performance des produits. La problématique de cette étude est la suivante :

Quels facteurs influencent la performance des produits de beauté et comment les exploiter pour optimiser les stratégies marketing ?

Les objectifs de cette analyse sont les suivants :

- Identifier les principaux facteurs influençant la performance des produits (prix, exclusivité, type de produit)
- Analyser la relation entre engagement client (avis, likes) et satisfaction (rating-note)
- Étudier l'évolution temporelle des comportements utilisateurs
- Proposer des recommandations business basées sur les données

2. Glossaire

Review (avis) : retour d'expérience d'un utilisateur après utilisation d'un produit

Rating (note) : évaluation du produit (1 à 5)

Likes (popularité) : indicateur d'intérêt et d'engagement

Performance produit : indicateur combinant popularité (likes) et satisfaction (Notes)

Produit exclusif : disponible uniquement sur la plateforme

Édition limitée : produit temporaire

Produit nouveau : récemment introduit

Échantillon : sous-ensemble de données utilisé pour l'analyse

3. Données et préparation

3.1 Structure initiale des données

<https://www.kaggle.com/datasets/nadyinky/sephora-products-and-skincare-reviews?resource=download>

Le dataset comprend :

- 1 Table **product_info**
- 5 tables de reviews :
 - Reviews_0-250
 - reviews_250-500
 - reviews_500-750
 - reviews_750-1250
 - reviews_1250-end

Ces fichiers ont été divisés pour des raisons techniques liées au volume des données. Les intervalles correspondent à des partitions de lignes et non à une variable d'analyse.

3.2 Choix de l'échantillon

Afin d'optimiser les performances et la lisibilité :

- 1 Table **product_info** avec **(8494, 27 colonnes)**
- 1 Table **reviews_0-250** avec **(602130, 19 colonnes)**

Ce choix permet :

- De conserver un volume représentatif
- D'éviter la complexité excessive
- D'améliorer la performance du modèle Power BI
- De faciliter l'interprétation des résultats

3.3 Fusion des données

Les données ont été combinées via Power Query :

- Import des tables produits et reviews
- Fusion des tables via la clé *product_id*
- Utilisation d'une jointure de type Left Join
- Expansion des colonnes produits dans la table reviews

Le dataset final obtenu est composé de :

- **602 130 lignes** (avis clients)
- **45 colonnes** (variables produits et interactions)

Chaque ligne correspond ainsi à un **avis client enrichi par les informations produit**, constituant la base principale pour l'analyse.

Ce dataset constitue le niveau d'analyse le plus détaillé (granularité : 1 ligne = 1 avis), Il permet d'analyser à la fois le comportement client et la performance produit.

3.4 Transformation des données

Les données ont fait l'objet d'un processus de préparation approfondi réalisé sous Power Query, visant à garantir la qualité, la cohérence et la fiabilité des analyses.

Les principales transformations effectuées sont les suivantes :

- Renommage des colonnes afin d'assurer une cohérence globale et une meilleure lisibilité du modèle de données
- Suppression des colonnes non pertinentes pour l'analyse (variables redondantes, informations non exploitables)
- Nettoyage des données : suppression des lignes contenant des valeurs nulles, égales à zéro ou incohérentes
- Vérification et correction des types de données (texte, numériques, dates) pour garantir la validité des calculs
- Standardisation des formats texte (gestion des majuscules/minuscules, harmonisation des libellés)
- Simplification de certaines variables textuelles (ex : limitation du nombre de mots à 3 pour améliorer la lisibilité dans les visualisations)
- Création de variables dérivées :
- Génération de variables booléennes pour faciliter les filtres analytiques
- Construction d'un indicateur de fiabilité des données, basé sur un seuil minimum de 50 avis par produit
- Filtrage des produits afin de ne conserver que les observations jugées statistiquement fiables
- Vérification de la cohérence des relations entre les tables (produits et avis) après transformation

Cette étape a permis d'obtenir un dataset structuré, nettoyé et prêt à être exploité pour une analyse robuste et pertinente.

Après nettoyage et préparation dans Power BI :

Le dataset final (Power BI) est prêt pour l'analyse : 598 651 lignes et 11 colonnes.

3.5 Agrégation

Afin de faciliter l'analyse au niveau produit, une table agrégée **Product_Summary** a été construite à partir du **Final_dataset Power BI**.

Cette transformation permet de passer d'une granularité fine (1 ligne = 1 avis) à une vision synthétique (1 ligne = 1 produit).

Les opérations réalisées incluent :

- Agrégation des données par *product_id*
- Calcul du nombre total d'avis par produit
- Calcul du rating moyen par produit
- Intégration du nombre total de likes par produit (en évitant les doublons liés à la granularité des avis)
- Ajout des caractéristiques produit : prix, marque, exclusivité, type d'édition, nouveauté

Cette étape est essentielle pour éviter la surestimation des indicateurs due à la répétition des données produit dans les avis.

Taille de la table Product_Summary choisi pour créer des tableaux de bord :

✓ (250 lignes, 10 colonnes)

4. Méthodologie

La performance produit est définie comme un indicateur composite basé sur deux dimensions complémentaires :

- **Popularité** : mesurée par le nombre total de likes
- **Satisfaction client** : mesurée par le rating (note) moyen

Afin de rendre ces deux variables comparables, une normalisation a été appliquée sur une échelle commune.

Les indicateurs d'avis et de likes sont utilisés comme proxy de l'expérience client, sans confirmation qu'ils résultent systématiquement d'un achat réel.

- Le score de performance est calculé comme suit :

$$\text{Score_performance} = 0.5 \times \text{Popularité_norm} + 0.5 \times \text{Satisfaction_norm}$$

Ce choix de pondération équilibrée (50/50) permet de refléter à la fois :

- L'attractivité des produits (engagement)
- Leur qualité perçue (satisfaction)

Deux niveaux d'analyse ont été définis :

- Analyse produit (globale) : identification des facteurs influençant la performance (prix, exclusivité, type de produit)
- Analyse temporelle : étude de l'évolution de l'engagement et de la satisfaction client entre 2008 et 2023

Cette approche permet de relier performance, comportement utilisateur et dynamique temporelle.

5. Résultats

5.1 Impact du prix

Les produits situés dans la tranche 20–50 USD présentent les meilleures performances, avec un score moyen atteignant 0.93, contre des scores inférieurs pour les autres segments.

Cette gamme offre un équilibre optimal entre accessibilité et perception de qualité.

5.2 Exclusivité vs engagement

Les produits exclusifs présentent une meilleure performance (**0.93**) que les produits non exclusifs (**0.79**).

Cependant, les produits non exclusifs génèrent un volume plus important d'engagement (avis et likes).

Cela met en évidence un arbitrage entre :

Performance qualitative (exclusivité)

Volume d'interaction (produits standards)

5.3 Type de produit

L'analyse met en évidence des écarts significatifs de performance selon le type de produit et son niveau de maturité sur le marché.

Les produits existants affichent un score de performance élevé (0.93) avec :

- 246 produits
- 29,4M de likes
- Une note moyenne de 4,30

À l'inverse, les nouveaux produits présentent un score nettement inférieur (0.53), malgré :

- Une note légèrement plus élevée (4,39)
- Mais un volume très limité (4 produits, 244K likes)

Cela suggère que la performance ne dépend pas uniquement de la satisfaction, mais fortement du niveau de visibilité et d'adoption.

Concernant le type d'édition :

Les éditions standards dominent largement en termes de performance (0.93) avec :

- 246 produits
- 29,3M de likes
- Une note moyenne de 4,31

En comparaison, les éditions limitées présentent une performance plus faible (0.57), avec :

- Seulement 4 produits
- 363K likes
- Une note légèrement inférieure (4,28)

Malgré une satisfaction comparable, leur faible volume limite leur impact global.

5.4 Produits les plus performants

L'analyse du **Top 50** met en évidence des produits avec des scores de performance élevés allant jusqu'à 0.93, reflétant une combinaison optimale entre popularité et satisfaction.

Ces produits représentent les meilleurs leviers d'optimisation du catalogue.

5.5 Analyse temporelle de l'engagement (2008–2023)

L'analyse de l'évolution du volume d'avis met en évidence une dynamique en trois phases distinctes.

Entre **2013 et 2020**, le nombre d'avis passe de 12K à 126K, traduisant une croissance très forte de l'engagement client.

Cette progression reflète une adoption croissante de la plateforme et une intensification des interactions utilisateurs.

L'année **2020 constitue un point de rupture majeur**, avec un niveau d'engagement maximal.

À partir de cette date, une phase de recul s'observe :

Diminution à 92K en 2021 puis 74K en 2022 jusqu'à 15K en 2023. Cela correspond à une baisse de près de -88% entre 2020 et 2023.

Après une phase de croissance rapide, l'engagement client entre dans une phase de déclin marqué post-2020, suggérant un changement de dynamique utilisateur ou de contexte marché.

5.6 Évolution de la satisfaction client

La note moyenne diminue progressivement, passant d'environ 4.5 à 4.2, soit une baisse d'environ 7%.

Toutefois, ce niveau reste élevé, avec une note supérieure à 4, ce qui traduit une satisfaction client globalement positive malgré cette légère dégradation.

5.7 Insight clé

L'augmentation du volume d'avis s'accompagne d'une baisse de la satisfaction client

Cela suggère que :

L'élargissement de la base utilisateur entraîne une plus grande diversité d'opinions et que maintenir la qualité perçue devient plus complexe à grande échelle.

6. Recommandations business

1. Positionnement prix optimisé

- ✓ Optimiser le positionnement prix sur la tranche 20–50 USD

2. Priorisation des produits performants

3. Stratégie mixte produit

- ✓ Produits exclusifs à forte valeur perçue
- ✓ Produits standards générant du volume
- ✓ Cela permet de maximiser à la fois performance et engagement.

4. Renforcement de la confiance produit

- ✓ Des avis clients
- ✓ Des notes visibles
- ✓ Des preuves sociales

5. Surveillance de la satisfaction client

6. Réactivation de l'engagement (focus 2023)

- ✓ Campagnes marketing ciblées
- ✓ Incitation à laisser des avis

- ✓ Amélioration de l'expérience utilisateur

7. Pilotage data-driven

- ✓ Prioriser les produits
- ✓ Optimiser le catalogue
- ✓ Orienter les décisions marketing

7. Limites

Absence de données de ventes réelles

L'analyse repose sur des indicateurs d'engagement et de perception (likes, avis, notes), sans accès aux données de ventes, ce qui limite l'évaluation directe de la performance commerciale.

Utilisation d'indicateurs indirects (proxy)

Les avis et les likes sont utilisés comme proxy de la perception client. Toutefois, l'absence d'indicateur de *verified purchase* ne permet pas de garantir que ces interactions proviennent systématiquement d'une expérience produit réelle.

Échantillonnage des données

L'analyse repose sur un sous-ensemble des données disponibles, ce qui peut limiter la représentativité globale des résultats.

Effet de la granularité et de l'agrégation

La transformation des données (passage d'un niveau "avis" à un niveau "produit") implique une agrégation qui peut masquer certaines variations individuelles ou comportementales.

Limitation de l'analyse temporelle

Les indicateurs de performance produit (likes) ne sont pas toujours liés à une dimension temporelle précise, ce qui limite l'interprétation fine des évolutions dans le temps.

8. Conclusion

Cette analyse met en évidence un enseignement central : les clients privilégient les produits connus, standards et déjà établis, qui bénéficient d'un niveau de confiance plus élevé et génèrent les meilleures performances.

Au-delà de ce constat, la performance des produits repose sur un équilibre entre visibilité, satisfaction client et positionnement prix.

Les résultats montrent que les produits les plus performants sont ceux qui parviennent à transformer l'intérêt en une expérience positive. À l'inverse, une forte exposition peut

s'accompagner d'une perception plus critique, soulignant l'importance de maintenir un haut niveau de qualité à mesure que la popularité augmente.

Par ailleurs, le positionnement prix apparaît comme un levier stratégique majeur, avec une concentration des meilleures performances sur les gammes intermédiaires (20–50 USD), combinant accessibilité et valeur perçue.

Enfin, la baisse de l'engagement observée après 2020, et plus particulièrement en 2023, met en évidence un risque de désengagement client. Cela souligne la nécessité, pour les acteurs du marché tels que Sephora, de réactiver l'interaction à travers des stratégies ciblées, centrées sur l'expérience utilisateur et la preuve sociale.

Dans ce contexte, une approche data-driven, fondée sur des indicateurs combinant popularité et satisfaction, permet d'orienter efficacement les décisions marketing, d'optimiser le portefeuille produit et de renforcer durablement la relation client.